

STATISTIKA DAN PROBABILITAS

AUDIT STATISTIK *PANDAS-DEV/PANDAS*

Dosen Pengampu: Muhammad Ridho Kurniawan Pratama, S.Kom., M.T.I.



Disusun Oleh:

Muhammad Rasyid Setyadi Dwi Putra	1519625018
Neisya Nurfadilah	1519625066
Adinda Syafira Kusumadewi	1519625028
Rafiif Ikbaar Taufiqulhakiim	1519620032
Muhammad Risqi Maulana	1519625032

SISTEM DAN TEKNOLOGI INFORMASI

FAKULTAS TEKNIK

UNIVERSITAS NEGERI JAKARTA

2026

1. *Executive Summary*

1. Audit ini menganalisis repositori *pandas-dev/pandas* menggunakan data isu dan *pull request* (PR) dari 1 Januari 2020 hingga 31 Desember 2024. Lima temuan di bawah ini dirumuskan sebagai poin tindak lanjut langsung bagi para *maintainer*.
2. Dari 2.592 PR, 69 persen berhasil di-*merge*. Sebanyak 1.789 PR diterima dengan probabilitas estimasi 0,69 dan selang kepercayaan 95 persen [0,67–0,71]. Sebaiknya tim meninjau 803 PR yang ditutup tanpa *merge* untuk memastikan tidak ada kontribusi yang seharusnya dapat digunakan.
3. Median waktu penyelesaian isu hanya 6 hari, tetapi distribusinya sangat miring ke kanan. Beberapa isu tercatat masih terbuka hingga lebih dari 200 hari. Pola ini menunjukkan adanya kelompok isu yang tidak mendapat perhatian dan perlu ditangani secara aktif melalui mekanisme triase.
4. Label *bug* dan *enhancement* tidak membedakan kecepatan penyelesaian. Uji Mann-Whitney U menghasilkan nilai-p 0,412, jauh di atas $\alpha = 0,05$. Artinya, kedua label ini tidak dapat dijadikan indikator urgensi dalam sistem triase saat ini.
5. Sekitar 28,4 persen isu membutuhkan lebih dari 30 hari untuk ditutup. Angka ini berasal dari simulasi Monte Carlo dengan 100.000 iterasi. Dengan proporsi hampir satu dari tiga isu, direkomendasikan adanya mekanisme pengingat otomatis pada isu yang belum direspons setelah 21 hari.
6. *Bloom Filter* yang diimplementasikan beroperasi pada kompleksitas $O(1)$ dengan tingkat *false positive* di bawah 1 persen. Pendekatan ini jauh lebih efisien dibandingkan pencarian linear untuk deteksi duplikasi isu pada skala repositori aktif.

2. *Data Overview* (Ikhtisar Data)

Data dikumpulkan langsung dari GitHub REST API melalui titik akhir <https://api.github.com/repos/pandas-dev/pandas/issues>, mencakup rentang waktu 1 Januari 2020 hingga 31 Desember 2024. Skrip pengumpulan tersimpan di *src/collect_data.py* dan menghasilkan berkas mentah *issues_raw.json* yang kemudian dibersihkan menjadi *data/clean/dataset.csv*.

2.1 Sumber dan Cakupan Data

Repositori *pandas-dev/pandas* dipilih karena memenuhi semua kriteria minimum audit secara bersamaan: lebih dari 1.000 isu tertutup, lebih dari 500 PR yang digabungkan, data *event* bertanda waktu, dan status proyek aktif. Selama periode yang diamati, sistem mencatat total 2.592 PR dan lebih dari 800 isu berlabel *bug* atau *enhancement* yang sudah ditutup.

2.2 Keterbatasan Data

Ada tiga hal yang perlu dicatat terkait kualitas data. Pertama, GitHub API membatasi jumlah permintaan per jam sehingga data yang terkumpul merupakan sampel, bukan sensus penuh seluruh aktivitas repositori. Kedua, sebagian isu tidak memiliki label apapun sehingga tidak dapat dimasukkan ke dalam analisis perbandingan *bug* versus *enhancement*. Ketiga, isu dengan waktu penyelesaian sangat panjang di ujung distribusi kemungkinan besar merupakan isu yang sengaja dibiarkan terbuka sebagai wadah diskusi berkelanjutan, bukan isu yang benar-benar tertunda.

3. *Parameter Estimation* (Estimasi Parameter)

Bagian ini menjawab pertanyaan penelitian P1: berapa probabilitas sebuah PR di-merge, dan seberapa besar ketidakpastiannya bila dimodelkan dengan distribusi Beta.

3.1 Estimasi MLE untuk Probabilitas Merge

Setiap PR diperlakukan sebagai percobaan Bernoulli independen dengan parameter θ yang merepresentasikan probabilitas PR diterima. *Maximum Likelihood Estimation* (MLE) untuk distribusi Binomial menghasilkan estimator yang sederhana sekaligus optimal secara asimtotik.

1. Langkah pertama adalah mendefinisikan fungsi *log-likelihood*. Dengan $n = 2.592$ percobaan dan $k = 1.789$ keberhasilan, fungsinya adalah:

$$\ell(\theta) = k \cdot \ln(\theta) + (n - k) \cdot \ln(1 - \theta)$$

2. Langkah kedua adalah menurunkan fungsi tersebut terhadap θ dan menyamakannya dengan nol, yang menghasilkan:

$$\theta_{MLE} = \frac{k}{n} = \frac{1.789}{2.592} \approx 0,6902$$


Estimator ini tak-bias dan konsisten. Meskipun secara numerik setara dengan proporsi sampel biasa, derivasi MLE memastikan bahwa tidak ada estimator tak-bias lain dengan variansi lebih kecil, sesuai batas bawah Cramér-Rao.

3.2 Pemodelan Posterior dengan Distribusi Beta

Karena θ adalah parameter probabilitas yang nilainya berada di $[0, 1]$, distribusi Beta merupakan *prior* konjugat alami untuk *likelihood* Binomial. Dengan menggunakan *prior* non-informatif $\text{Beta}(1, 1)$ yang setara dengan distribusi seragam, distribusi *posterior*-nya adalah:

$$\theta \mid \text{data} \sim \text{Beta}(\alpha + k, \beta + n - k) = \text{Beta}(1790, 804)$$

Mean *posterior* dari distribusi ini adalah $1790 / (1790 + 804) \approx 0,6902$, konsisten dengan estimasi MLE. Distribusi Beta juga memungkinkan perhitungan *credible interval* Bayesian secara langsung tanpa bergantung pada asumsi normalitas asimtotik.



Gambar 1. Distribusi status *Pull Request* pandas-dev/pandas (2020–2024). Dari 2.592 PR, sebanyak 1.789 (69%) berhasil di-*merge* dan 803 (31%) ditutup tanpa *merge*.

4. *Confidence Intervals* (Selang Kepercayaan)

Selang kepercayaan (*confidence interval*, CI) mengukur ketidakpastian estimasi parameter dalam kerangka *frequentist*. Interpretasi yang tepat: bila prosedur pengambilan sampel yang sama diulang berkali-kali, 95 persen dari selang yang terbentuk akan mencakup nilai parameter populasi yang sebenarnya. Ini berbeda dari pernyataan bahwa parameter berada di dalam satu selang tertentu dengan peluang 95 persen.

4.1 CI untuk Probabilitas *Merge* PR

Karena n sangat besar, aproksimasi normal (metode Wald) berlaku dan standar galat estimasi dapat dihitung sebagai:

$$SE = \sqrt{\frac{\theta(1 - \theta)}{n}} = \sqrt{\frac{0,6902 \cdot 0,3098}{2.592}} \approx 0,0091$$

Selang kepercayaan 95 persen diperoleh dengan mengalikan standar galat dengan nilai kritis $z = 1,960$:

$$CI_{95\%} = \theta \pm 1,960 \times SE = [0,6724 ; 0,7080]$$


Selang $[0,67 ; 0,71]$ menunjukkan bahwa secara konsisten sekitar dua pertiga PR diterima. Lebar selang yang sempit (sekitar $\pm 0,02$) mencerminkan bahwa ukuran sampel 2.592 sudah cukup untuk menghasilkan estimasi yang presisi.

4.2 CI untuk Rata-rata Waktu Penyelesaian Isu

Meskipun distribusi waktu penyelesaian sangat miring ke kanan, *Central Limit Theorem* memungkinkan penggunaan distribusi-t untuk membangun selang kepercayaan rata-rata. Dari data bersih diperoleh $\hat{\mu} = 21,4$ hari, $s = 38,7$ hari, dan $n = 847$ isu:

$$CI_{95\%} = \hat{\mu} \pm t_{\{0,025\}} \times \frac{s}{\sqrt{n}} \approx [18,8 ; 24,0] \text{ hari}$$

Lebar selang sekitar $\pm 2,6$ hari mencerminkan variansi yang tinggi dalam data, konsisten dengan bentuk distribusi yang sangat *right-skewed* seperti terlihat pada Gambar 2.



Gambar 2. Distribusi waktu penyelesaian isu (kiri) dan box plot log-transformasi (kanan). Median 6 hari menunjukkan bahwa sebagian besar isu diselesaikan cepat, tetapi sejumlah *outlier* jauh di atas 100 hari menarik rata-rata ke angka 21,4 hari.

5. *Hypothesis Testing* (Pengujian Hipotesis)

Bagian ini menjawab pertanyaan penelitian P2: apakah waktu penyelesaian isu berbeda secara signifikan antara kategori *bug* dan *enhancement*. Prosedur enam langkah standar diikuti di bawah ini.

5.1 Pernyataan Hipotesis

- H_0 : Distribusi waktu penyelesaian isu *bug* dan *enhancement* identik, tidak ada perbedaan.
- H_1 : Distribusi waktu penyelesaian isu *bug* dan *enhancement* berbeda.

5.2 Pemilihan Uji Statistik

Distribusi waktu penyelesaian tidak memenuhi asumsi normalitas, dikonfirmasi dengan uji Shapiro-Wilk yang menghasilkan $p < 0,001$ untuk kedua kelompok. Oleh karena itu, uji-t dua sampel tidak dapat digunakan. Sebagai gantinya dipilih *Mann-Whitney U test*, sebuah uji non-parametrik yang membandingkan peringkat dari dua kelompok tanpa mengasumsikan bentuk distribusi tertentu.

5.3 Tingkat Signifikansi

Tingkat signifikansi ditetapkan pada $\alpha = 0,05$, sesuai konvensi standar dalam analisis statistik.

5.4 Perhitungan Statistik Uji


Data menunjukkan 412 isu berlabel *bug* dengan median 8 hari dan 435 isu berlabel *enhancement* dengan median 9 hari. Statistik *Mann-Whitney U* yang dihitung adalah $U = 88.234$ dengan nilai-p ($p\text{-value}$) = 0,412.

5.5 Keputusan Statistik

Karena nilai-p yang diperoleh (0,412) jauh melebihi $\alpha = 0,05$, keputusannya adalah gagal menolak H_0 . Penting untuk dicatat bahwa dalam kerangka *frequentist*, formulasi yang benar adalah ‘gagal menolak H_0 ’ dan bukan ‘menerima H_0 ’, sebab tidak adanya bukti penolakan tidak setara dengan bukti penerimaan.

5.6 Interpretasi

Pada tingkat signifikansi 5 persen, tidak cukup bukti statistik untuk menyimpulkan bahwa isu *bug* diselesaikan dalam waktu berbeda dibandingkan isu *enhancement*. Selisih median 1 hari (8 berbanding 9 hari) tidak bermakna secara statistik maupun secara praktis. Temuan ini menunjukkan bahwa sistem pelabelan yang ada saat ini tidak mencerminkan perbedaan urgensi, sehingga proses triase perlu mempertimbangkan dimensi lain seperti tingkat keparahan dampak atau frekuensi laporan serupa.



Gambar 3. Perbandingan waktu penyelesaian isu *bug* vs *enhancement* (dipotong di 200 hari). Kedua distribusi tampak hampir identik, konsisten dengan hasil uji Mann-Whitney U yang tidak signifikan.

6. *Computational Analysis* (Analisis Kotasional)

Bagian ini menjawab pertanyaan penelitian P3 sekaligus menjelaskan mengapa masing-masing teknik komputasional dipilih untuk permasalahan yang dihadapi.

6.1 Simulasi Monte Carlo

P3 meminta estimasi probabilitas sebuah isu membutuhkan lebih dari 30 hari untuk ditutup. Simulasi Monte Carlo dipilih karena distribusi waktu penyelesaian tidak mengikuti distribusi analitik standar, baik eksponensial maupun normal. Tanpa bentuk distribusi yang jelas, derivasi probabilitas secara *closed-form* mengharuskan asumsi yang tidak didukung data.

Prosedur yang diimplementasikan di *src/simulation.py* dan dijalankan melalui *notebooks/05_simulation.ipynb* mencakup tiga tahap. Distribusi empiris waktu penyelesaian di-*fit* menggunakan *kernel density estimation*. Kemudian 100.000 nilai diambil secara acak dari distribusi tersebut. Proporsi nilai yang melebihi 30 hari dihitung sebagai estimasi probabilitas.

Hasilnya adalah 0,284 dengan selang kepercayaan *bootstrap* 95 persen [0,255 ; 0,313]. Hampir tiga dari sepuluh isu diperkirakan membutuhkan lebih dari sebulan. Monte Carlo tepat digunakan di sini karena metode ini tidak bergantung pada asumsi distribusi, standar galatnya sangat kecil ($< 0,001$) dengan 100.000 iterasi, dan hasilnya dapat diperbarui otomatis saat data baru masuk.

6.2 *Bloom Filter* untuk Deteksi Duplikasi Isu

Repositori aktif dengan ribuan isu rentan terhadap laporan duplikat dari kontributor berbeda untuk masalah yang sama. Pencarian linear konvensional memiliki kompleksitas $O(n)$ yang menjadi lambat seiring bertambahnya data.

Bloom Filter dipilih karena menawarkan pengecekan keanggotaan pada kompleksitas $O(k)$, di mana k adalah jumlah fungsi *hash* yang digunakan. Implementasi di *src/simulation.py* mengonfigurasi kapasitas 10.000 elemen dengan tingkat *false positive* di bawah 1 persen, dicapai melalui 7 fungsi *hash* dan *bit array* berukuran 95.851 bit.

Bloom Filter tidak menghasilkan *false negative*, artinya bila *filter* menyatakan sebuah isu belum pernah dilaporkan, pernyataan itu pasti benar. Potensi *false positive* yang ada dapat ditangani dengan verifikasi sekunder. Justifikasi penggunaannya di sini bukan akurasi absolut, melainkan efisiensi memori dan kecepatan respons pada skala besar.

6.3 MCMC untuk Posterior Sampling

Markov Chain Monte Carlo (MCMC) digunakan dalam *notebooks/05_simulation.ipynb* untuk mengambil sampel dari distribusi *posterior* ketika *prior* yang lebih informatif diterapkan dan bentuk *posterior*-nya tidak lagi memiliki ekspresi analitik sederhana. Untuk model Binomial dasar, distribusi Beta sudah cukup, tetapi MCMC mempersiapkan infrastruktur yang diperlukan bila model diperluas dengan kovariat seperti ukuran PR atau jumlah *reviewer*.

Algoritma Metropolis-Hastings dijalankan selama 50.000 iterasi dengan 10.000 iterasi *burn-in*. Konvergensi dikonfirmasi melalui *Gelman-Rubin statistic* $\hat{R} < 1,01$, yang menunjukkan bahwa *chain* sudah mencapai distribusi stasioner. MCMC dipilih karena mampu menjelajahi ruang parameter berdimensi tinggi tanpa perlu menurunkan distribusi *posterior* secara analitik.

7. *Recommendations* (Rekomendasi)

Dua rekomendasi berikut diajukan kepada tim *maintainer* berdasarkan temuan kuantitatif dalam audit ini. Keduanya bersifat spesifik dan dapat dilaksanakan tanpa perubahan infrastruktur besar.

7.1 Terapkan Pengingat Otomatis untuk Isu yang Tidak Direspons

Simulasi Monte Carlo menunjukkan 28,4 persen isu membutuhkan lebih dari 30 hari untuk ditutup, sementara mediannya hanya 6 hari. Kesenjangan ini bukan sekadar variasi alami, melainkan mengindikasikan dua kelompok isu yang berperilaku berbeda: isu yang diselesaikan cepat dan isu yang tenggelam tanpa tindak lanjut.

Solusi praktisnya adalah mengimplementasikan GitHub Action berbasis *stale* yang secara otomatis menambahkan label *needs-attention* pada isu tanpa respons setelah 21 hari, kemudian mengirim notifikasi ke saluran *triage* tim setelah 30 hari. Ambang 21 hari memberi jendela 9 hari bagi *maintainer* untuk merespons sebelum sebuah isu masuk ke dalam 28 persen yang berisiko mangkrak. Implementasi ini dapat diselesaikan dalam satu hari kerja menggunakan Action yang sudah tersedia di GitHub Marketplace.

7.2 Pisahkan Dimensi Kategori dan Urgensi dalam Sistem Label

Hasil uji Mann-Whitney U memperlihatkan bahwa label *bug* dan *enhancement* tidak membedakan kecepatan penyelesaian. Kedua label ini tampaknya digunakan untuk menandai jenis masalah, bukan menandai seberapa mendesak masalah itu diselesaikan. Akibatnya, sistem triase kehilangan sinyal prioritas yang berguna.

Rekomendasi konkretnya adalah menambahkan label prioritas yang terpisah, misalnya *priority: critical*, *priority: high*, *priority: medium*, dan *priority: low*. Dengan skema ini, pertanyaan ‘apa jenis masalahnya’ dan ‘seberapa mendesak penanganannya’ dijawab oleh dua dimensi label yang

berbeda. *Maintainer* dapat mengurutkan *backlog* berdasarkan urgensi aktual, bukan sekadar kategori, sehingga alokasi waktu tim lebih terarah. Perubahan ini dapat diterapkan langsung pada isu-isu baru tanpa migrasi data historis.

Referensi

Tsun, A. (2020). *Probability and Statistics for Engineers and Scientists*. Penerbit Universitas.

GitHub. (2024). *REST API endpoints for issues*. Diakses dari <https://docs.github.com/en/rest/issues/issues>

GitHub. (2024). *pandas-dev/pandas*. Diakses dari <https://github.com/pandas-dev/pandas>